

Modèle Linéaire pour classification

Classification linéaire: **Introduction**

Question: Comment adopter le modèle linéaire
à la classification?

Classification linéaire: Classification binaire

Une classification **binaire** a **2 classes**

Dans ce genre de problème, on aura un Dataset contenant une variable target y pouvant prendre **2** valeurs seulement,


($y' = \{-1,1\}$):

- $g(x) = sign(y - w^T x)$
- $d + 1$ paramètres

Exemple:

Pour une Dataset d'emails

- si $y = -1$, alors l'email n'est pas un spam
- si $y = 1$, alors l'email est un spam



Classification linéaire: **Classification binaire**

Classification binaire: ($y' = \{-1,1\}$):


- $g(x) = \text{sign}(y - w^T x)$
- $d + 1$ paramètres

Exemple:

Pour une Dataset d'emails

- si $y = -1$, alors l'email n'est pas un spam
- si $y = 1$, alors l'email est un spam

Classification binaire: Logistic Regression(1)




- le modèle de régression logistique est utilisé pour résoudre les problèmes **de classification binaire**,
- Le modèle est linéaire $g(x) = w^T x$
- La fonction d'activation: on applique la fonction logistique (aussi appelé fonction sigmoïde ou tout simplement sigma σ) sur la sortie linéaire

$$\sigma(x) = \frac{1}{1 + e^{-w^T x}}$$

- Cette fonction permet de transformer le modèle linéaire en une fonction non linéaire toujours comprise en 0 et 1.

Classification binaire: Logistic Regression(2)




- A partir de cette fonction, il est possible de définir un **seuil**,
- Typiquement, on définit le seuil à **0.5** comme ceci :

$$\begin{cases} y=-1 \text{ si } \sigma(X.\theta) < 0.5 \\ y=1 \text{ si } \sigma(X.\theta) \geq 0.5 \end{cases}$$


Classification linéaire: Classification multiple

- Logistic regression applies only to binary classification problems. For multi-class classification problems, use the Softmax function.

Binary classification problem



Multi-class classification problem



Classification linéaire: Classification multi-classes (K classes)

- Classification multi-classes ($y \in \{1, \dots, K\}$):

$$g(x) = \arg \max_{k \in \{1, \dots, K\}} (w_k^T x)$$

- Nombre de paramètres: $K \times d$ ($w_k \in \mathbb{R}^d$)
- Exemple:

$$\begin{aligned} z &= (7, -7, 5, 10) \text{ scores} \\ g(x) &= 3 \end{aligned}$$

Classification multi-classes: **SoftMax function**

- Calculer des **scores positifs, compris entre 0 et 1 sous forme d'une distribution de probabilités** (logits) à partir du modèle linéaire:
- On applique **SoftMax transform**

$$z = (w_1^T x, \dots, w_K^T x)$$

$$(z_1, z_2, \dots, z_K)$$

$$(e^{z_1}, \dots, e^{z_K})$$

$$\sigma(z) = \left(\frac{e^{z_1}}{\sum_{k=1}^K e^{z_k}}, \dots, \frac{e^{z_K}}{\sum_{k=1}^K e^{z_k}} \right)$$

SoftMax function

Classification linéaire: softmax function

$$\sigma(z) = \left(\frac{e^{z_1}}{\sum_{k=1}^K e^{z_k}}, \dots, \frac{e^{z_K}}{\sum_{k=1}^K e^{z_k}} \right)$$

Exemple

$$z = (7, -7.5, 10)$$

$$\sigma(z) = (0.05, 0, 0.95)$$

Classification linéaire: Loss function?

- output du modèle: prédiction des probabilités des classes

$$\sigma(z) = \left(\frac{e^{z_1}}{\sum_{k=1}^K e^{z_k}}, \dots, \frac{e^{z_K}}{\sum_{k=1}^K e^{z_k}} \right)$$

- La valeur des targets pour la probabilité des classes

$$p = ([y = 1], \dots, [y = K])$$

[a]: Iverson brackets:

$$[a] = \begin{cases} 1 & \text{Si } a \text{ est true} \\ 0 & \text{Si } a \text{ est false} \end{cases}$$

- La similarité entre z et p peut être mesurée par l'entropie croisée (Cross entropy)

$$-\sum_{k=1}^K [y = k] \log \frac{e^{z_k}}{\sum_{k=1}^K e^{z_k}} = -\log \frac{e^{z_y}}{\sum_{j=1}^K e^{z_j}}$$

Classification linéaire: cross entropy exemple

Suppose $K = 3$ and $y = 1$:

- $-1 * \log 1 - 0 * \log 0 - 0 * \log 0 = 0$
- $-1 * \log 0.5 - 0 * \log 0.25 - 0 * \log 0.25 \approx 0.693$
- $-1 * \log 0 - 0 * \log 1 - 0 * \log 0 = +\infty$

Classification linéaire: cross entropy pour classification

La fonction **cross-entropy** est différentiable et peut être utilisée comme **Loss Function**

-

$$L(w) = - \sum_{i=1}^l \sum_{k=1}^K [y_i = k] \log \frac{e^{w_k^T x_i}}{\sum_{j=1}^K e^{w_j^T x_i}}$$

$$-\sum_{i=1}^l \log \frac{e^{w_{y_i}^T x_i}}{\sum_{j=1}^K e^{w_j^T x_i}} \rightarrow \min_w L(w)$$

Classification linéaire: Récapitulatif

- Les modèles linéaires peuvent facilement généralisés pour les tâches de classification
- Régression-----→ Loss Function : MSE (Mean Squared Error)
- Classification-----→ Loss Function: Cross Entropy