

Data Mining

Analyse et Fouille de données



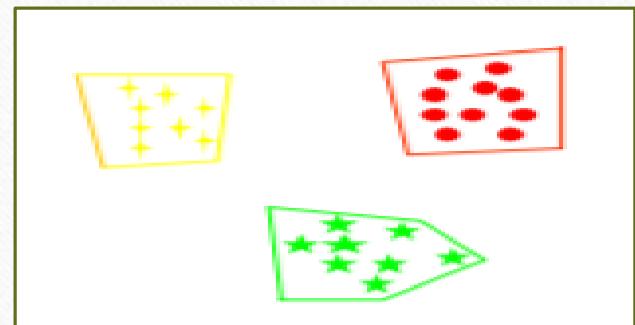
Dr. Sana Hamdi

sana.hamdi@fst.utm.tn

Introduction

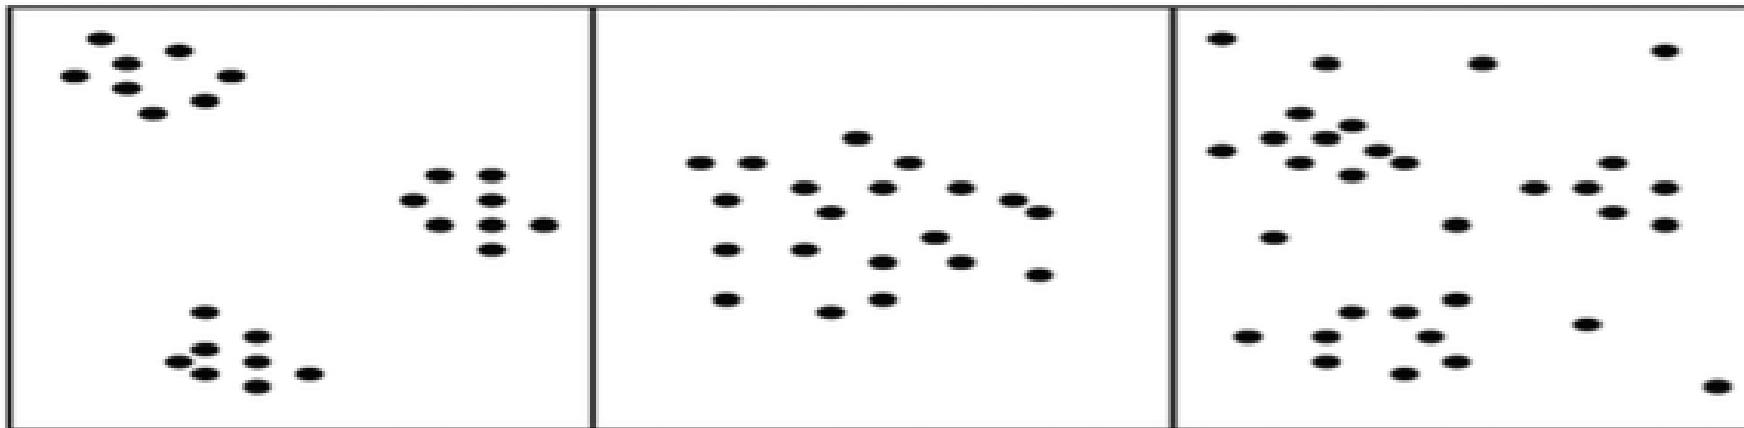
Le Clustering

- C'est une approche qui partitionne un ensemble de données en sous-classes (clusters) ayant du sens.
- Il s'agit de regrouper les points proches/similaires en « paquets ou groupes ou classes »
- Optimiser le regroupement: Une bonne méthode va produire des clusters tout en:
 - ✓ Maximisant la similarité intra-classe
 - ✓ Minimisant la similarité inter-classes
- La qualité d'un clustering dépend de la mesure de similarité



Le Clustering

- MAIS les groupes peuvent être assez bien définis et séparés, ou au contraire imbriqués/sans frontières claires, et de formes quelconques



Applications

Domaine	Forme des données	Clusters
Text mining	Textes, Mails	Textes proches, Dossiers automatiques
Web mining	Textes et images	Pages Web proches
Bio-informatique	Gènes	Gènes ressemblants
Marketing	Infos Clients, produits achetés	Segmentation de la clientèle
Segmentation d'images	Images	Zones homogènes dans l'image
Web log Analysis	ClickStream	Profils utilisateurs, groupes d'accès similaires

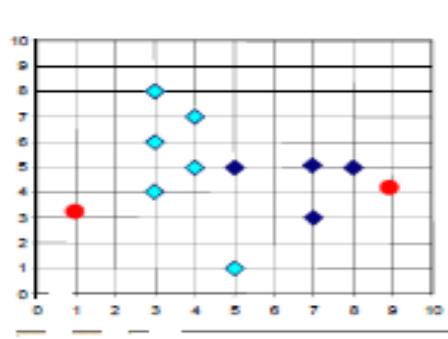
Partitionnement

- Construire une partition à k clusters d'un jeu de données D de n objets
- Les k clusters doivent optimiser le critère de partitionnement choisi (fonction de similarité)
- Critère de performance : l'erreur est définie comme la distance euclidienne entre individus et centres des groupes
- Approches heuristiques :
 - K-means : chaque cluster est représenté par son centre de gravité
 - K-medoids ou *PAM (partition around medoids)* : chaque cluster est représenté par un objet du cluster

Algorithme des k-moyennes

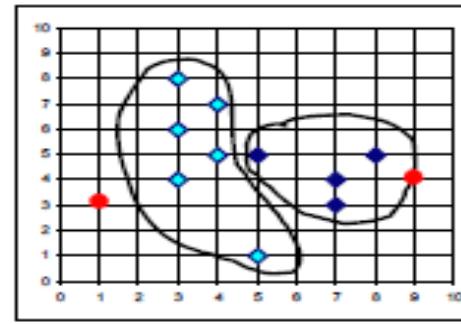
1. Choisir k objets les représentants initiaux de k clusters
2. (Ré)affecter chaque objet O au cluster C_i de centre M_i tel que $d(O, M_i)$ est minimal
3. Recalculer M_i de chaque cluster (le barycentre)
4. Aller à l'étape 2 et 3 jusqu'à ce qu'il n'y ait plus (ou peu) de changement dans les clusters

k-moyennes: Trace d'exécution



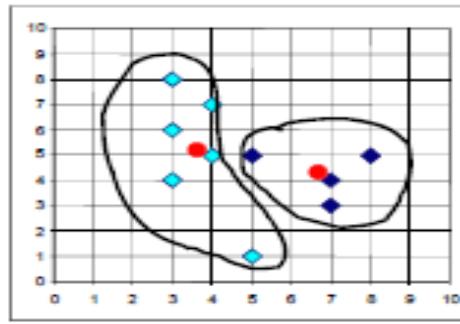
K=2 choisir deux objets comme centre

affecter tous les objets au centre le plus proche



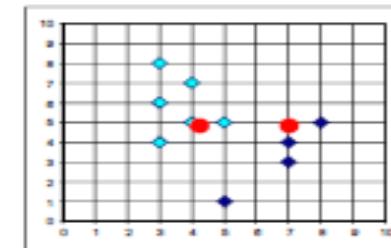
réaffecter

mettre à jour les centres des segments



réaffecter

mettre à jour les centres des segments



k-moyennes: Exemple

- $A = \{1, 2, 3, 6, 7, 8, 13, 15, 17\}$. Créer 3 clusters à partir de A
- On prend 3 objets au hasard. Supposons que c'est 1, 2 et 3. Ca donne:
 - $C_1 = \{1\}, M_1 = 1$,
 - $C_2 = \{2\}, M_2 = 2$,
 - $C_3 = \{3\}$ et $M_3 = 3$
- Chaque objet O est affecté au cluster dont le centre est le plus proche.
- 6 est affecté à C_3 car $d(M_3, 6) < d(M_2, 6)$ et $d(M_3, 6) < d(M_1, 6)$
- On a:
 $C_1 = \{1\}, M_1 = 1$,
 $C_2 = \{2\}, M_2 = 2$
 $C_3 = \{3, 6, 7, 8, 13, 15, 17\}, M_3 = 69/7 = 9.86$

k-moyennes: Exemple

- $d(3, M_2) < d(3, M_3)$ → 3 passe dans C_2 . Tous les autres objets ne bougent pas.

$C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$

- $d(6, M_2) < d(6, M_3)$ → 6 passe dans C_2 . Tous les autres objets ne bougent pas.

$C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$

- $d(2, M_1) < d(2, M_2)$ → 2 passe en C_1 . $d(7, M_2) < d(7, M_3)$ → 7 passe en C_2 . Les autres ne bougent pas.

$C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$

- $d(3, M_1) < d(3, M_2)$ → 3 passe en 1. $d(8, M_2) < d(8, M_3)$ → 8 passe en 2

$C_1 = \{1, 2, 3\}$, $M_1 = 2$, $C_2 = \{6, 7, 8\}$, $M_2 = 7$, $C_3 = \{13, 15, 17\}$, $M_3 = 15$

Plus rien ne bouge

Indice de validité: Silhouette

- L'erreur n'est pas un bon indice de qualité/validité : n'est basée que sur la dispersion intra-groupes
- Le score de silhouette se définit d'abord sur un point i dont le groupe est k
- Il se base sur:
 - la distance moyenne du point à son groupe: $a(i) = \frac{1}{|I_k|-1} \sum_{j \in I_k, j \neq i} d(x^i, x^j)$
 - la distance moyenne du point à son groupe voisin: $b(i) = \min_{k' \neq k} \frac{1}{|I_{k'}|} \sum_{i' \in I_{k'}} d(x^i, x^{i'})$.
 - Avec I_k est l'ensemble des points appartenant à un groupe k

Indice de validité: Silhouette

- Le coefficient de silhouette du point i s'écrit alors:
- On peut le moyenner groupe par groupe pour comparer leurs homogénéités : ceux avec les coefficient de silhouette les plus forts sont les plus homogènes. Sur l'ensemble de la classification, il aura pour expression

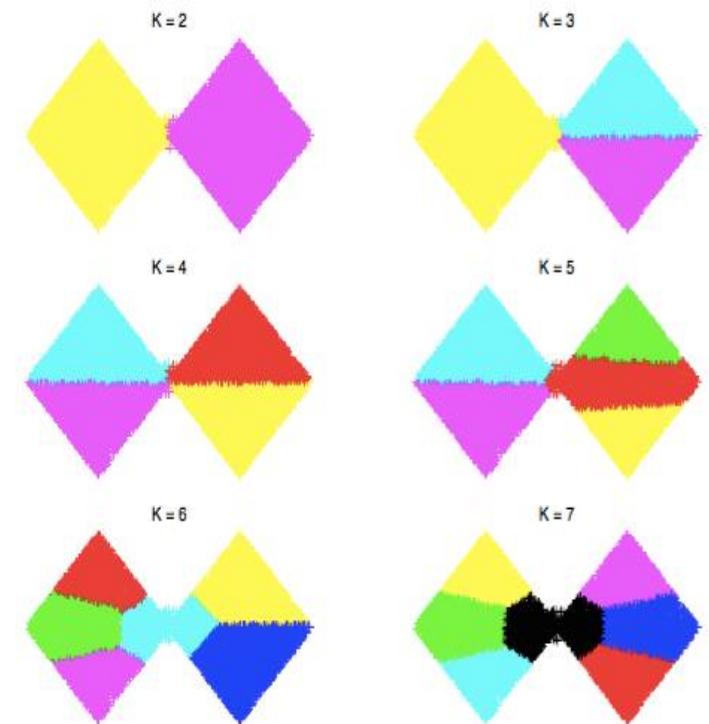
$$S_{sil} = \frac{1}{K} \sum_{k=1}^K \frac{1}{|I_k|} \sum_{i \in I_k} s_{sil}(i)$$

- Le coefficient de silhouette varie entre -1 (pire classification) et 1 (meilleure classification)
- Choisir le K qui maximise le coefficient de Silhouette

Variantes de k-moyennes

Les variantes des K-Means diffèrent dans :

- La sélection des k initiaux
- Calcul de la dissimilarité (distance)
- Stratégies pour calculer la moyenne d'un cluster



k-moyennes: Intérêts

- L'algorithme converge en général pour les mesures typiques de similarité.
- Souvent l'algorithme converge en quelques itérations.
- Relativement efficace: $O(t*k*n)$, où n est nombre objets, k est nombre de clusters, et t est le nombre d'itérations. Normalement, $k, t \ll n$.



k-moyennes: limites

- Utilisable seulement lorsque la moyenne est définie. Que faire dans le cas de données nominales ?
- On doit spécifier k en avance (nombre de clusters)
- Les clusters sont construits par rapport à des objets inexistant (les milieux)
- Ne gère pas le bruit et les exceptions



Algorithme des k-médoïdes (PAM)

- Trouve des représentants, appelés médoïdes, dans les clusters
- PAM (*partition around medoids*) :
 - ❖ médoïde : l'objet d'un cluster pour lequel la distance moyenne à tous les autres objets du cluster est minimale
 - ❖ critère d'erreur : $E = \sum_{i=1}^k \sum_{p \in c_i} d(p, mi)^2$

Algorithme des k-médoïdes (PAM)

1. Sélectionner k objets arbitrairement
2. Assigner le reste des objets au médoïde le plus proche
3. Sélectionner un objet non médoïde et échanger si le critère d'erreur peut être réduit
4. Répéter 2 et 3 jusqu'à ne plus pouvoir réduire le critère d'erreur

k-médoïdes : exemple

- Soit $A = \{1, 3, 4, 5, 8, 9\}$, $k=2$ et $M = \{1, 8\}$ ensemble des medoides $\rightarrow C1 = \{\underline{1}, 3, 4\}$ et $C2 = \{5, \underline{8}, 9\}$
 $E_{\{1,8\}} = d(3,1)^2 + d(4,1)^2 + d(5,8)^2 + d(9,8)^2 = \textcolor{red}{23}$
- Comparons 1 et 3 $\rightarrow M = \{3, 8\} \rightarrow C1 = \{1, \underline{3}, 4, 5\}$ et $C2 = \{\underline{8}, 9\}$
 $E_{\{3,8\}} = d(1,3)^2 + d(4,3)^2 + d(5,3)^2 + d(9,8)^2 = \textcolor{green}{10}$
 $E_{\{3,8\}} - E_{\{1,8\}} = -29 < 0$ donc le remplacement est fait.
- Comparons 3 et 4 $\rightarrow M = \{4, 8\} \rightarrow C1$ et $C2$ inchangés et
 $E_{\{4,8\}} = d(1,4)^2 + d(3,4)^2 + d(5,4)^2 + d(8,9)^2 = \textcolor{red}{12} \rightarrow$ 3 n'est pas remplacé par 4
- Comparons 3 et 5 $\rightarrow M = \{5, 8\} \rightarrow C1$ et $C2$ inchangés et $E\{5,8\} > E\{3,8\}$

k-médoïdes : exemple

