

# Data Mining

---

Apprentissage et Fouille de données

Dr. Sana Hamdi

[sana.hamdi@fst.utm.tn](mailto:sana.hamdi@fst.utm.tn)

# Les règles d'association



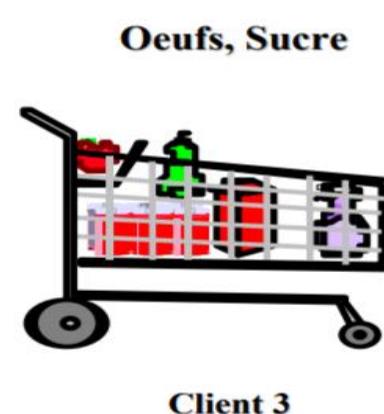
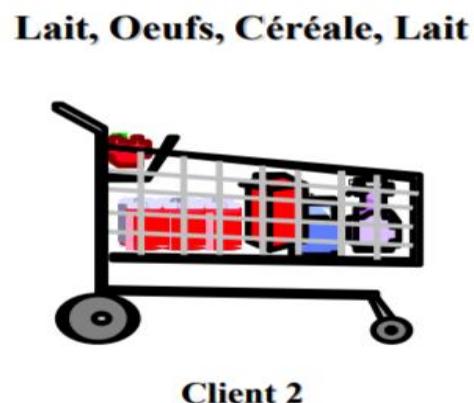
# Recherche d'associations

- **Règles d'association** : consiste à déterminer les items qui sont associées.
  - **Motifs de la forme** : prémissse  $\Rightarrow$  conclusion
  - **Exemple type** : Détermination des articles qui se retrouvent ensemble sur un même ticket de supermarché (achète(x, “fromage”)  $\Rightarrow$  achète(x, “pain”) )
    - ✓ Intéressant pour identifier des opportunités de vente croisée et concevoir des groupements attractifs de produit.
    - ✓ Nécessité de très grands jeux de données.

Rech.Nr. 4572		30.07.2007/13:29/17		Rech.Nr. 4572		30.07.2007/13:29/17	
Bar		Tisch	7/0	Bar		Tisch	7/0
Wurstkäse Macchiatto	4.50 CHF	9.00		Wurstkäse Macchiatto	4.50 CHF	9.00	
Wurstkäse	5.00	5.00		Wurstkäse	5.00	5.00	
Wurstschweinbrötchen	22.00 CHF	22.00		Wurstschweinbrötchen	22.00 CHF	22.00	
Wurstschweinbrötchen	18.50 CHF	18.50		Wurstschweinbrötchen	18.50 CHF	18.50	
Total :	CHF	<b>54.50</b>		Total :	CHF	<b>54.50</b>	
Incl. T. Et. M&P	54.50 CHF	3.85		Incl. T. Et. M&P	54		
Entsprech. In Euro	36.33 EUR			Entsprech. In Euro	36.33 EUR		
Es bediente Stkr. Ursula				Es bediente Stkr. Ursula			
M&P Nr.:	430 234			M&P Nr.:	430 234		
Tel.:	033 853 67 16			Tel.:	033 853 67 16		
Fax.:	033 853 67 19			Fax.:	033 853 67 19		
E-mail:	grossescheide@bluewin.ch			E-mail:	grossescheide@bluewin.ch		

# Exemple: Analyse du panier de la ménagère

- La base de données a pour tuples les consommateurs et chaque tuple est un ensemble d'items.



- Déterminer des groupes d'items qui sont **fréquemment** achetés simultanément

# Recherche d'associations

Numéro de la transaction	Contenu de caddie		
	P1	P2	P3
1	P1	P2	P3
2	P1	P3	
3	P1	P2	P3
4	P1	P3	
5	P2	P3	
6	P4		

Dès qu'on a des données binaires, il est possible de construire des **règles d'association**.

Transaction	P1	P2	P3	P4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

# Recherche d'associations

Observation	Taille	Corpulence
1	petit	mince
2	grand	enveloppé
3	grand	mince

Dès qu'on a des données binaires, il est possible de construire des **règles d'association**.

Observation	Taille = petit	Taille = grand	Corpulence = mince	Corpulence = enveloppé
1	1	0	1	0
2	0	1	0	1
3	0	1	1	0

# Recherche d'associations

## Objectifs:

- Mettre en évidence les produits achetés ensemble.
- Transcrire la connaissance sous forme de règle d'association.

→ *Si antécédent Alors conséquent*

liste des produits

Transaction	P1	P2	P3	P4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

# Mesures: Support et Confiance

---

- **Support:** un indicateur de fiabilité de la règle (Si X alors Y): la proportion de transactions qui contiennent à la fois X et Y

$$\text{Support } (X \Rightarrow Y) = P(X \text{ et } Y)$$

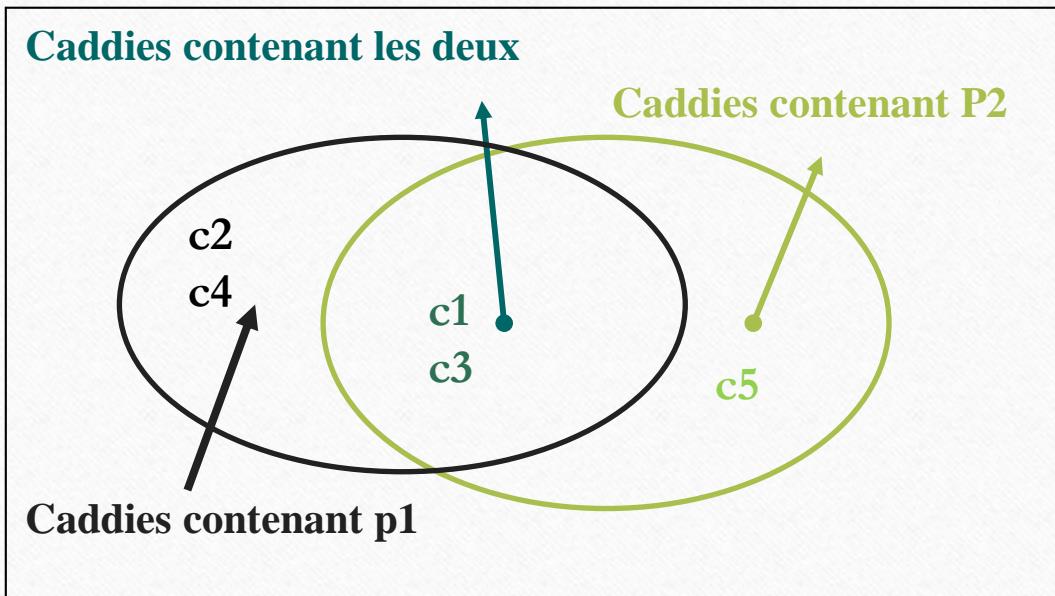
- **Confiance:** un indicateur de précision de la règle (Si X alors Y): la proportion de transactions contenant X, contiennent aussi Y

$$\begin{aligned}\text{Confiance } (X \Rightarrow Y) &= P(Y | X) = P(X \text{ et } Y) / P(X) \\ &= \text{Support } (X \Rightarrow Y) / \text{Support } (X)\end{aligned}$$

- Bonne règle possède un support et confiance élevés.

# Mesures: Support et Confiance

- Soit la règle d'association **R1: Si p1 alors p2**



Caddie	P1	P2	P3	P4
c1	1	1	1	0
c2	1	0	1	0
c3	1	1	1	0
c4	1	0	1	0
c5	0	1	1	0
c6	0	0	0	1

# Mesures: Support et Confiance

- Soit la règle d'association **R1: Si p1 alors p2**

- **Support(R1) = 2/6 = 33%**
- **Confiance(R1) = (2/6) / (4/6) = 50%**

Caddie	P1	P2	P3	P4
c1	1	1	1	0
c2	1	0	1	0
c3	1	1	1	0
c4	1	0	1	0
c5	0	1	1	0
c6	0	0	0	1

# Recherche d'associations: Notions utiles

---

- **Objectif:** trouver toutes les règles associatives, respectant MinSup et MinConf
- **Seuils minimaux de support et confiance donnés par l'utilisateur:**
  - MinSup
  - MinConf
- **Décomposition du problème:**
  1. Détermination des itemsets fréquents ( $\text{support} \geq \text{MinSup}$ )
  2. Génération des règles associatives ( $\text{confiance} \geq \text{MinConf}$ )

# Recherche d'associations

---

## ❖ MinSup

- **Elevé** ⇒ peu d'itemsets fréquents  
⇒ peu de règles valides qui ont été souvent vérifiées
- **Réduit** ⇒ plusieurs règles valides qui ont été rarement vérifiées

## ❖ MinConf

- **Elevée** ⇒ peu de règles, mais toutes « pratiquement » correctes
- **Réduite** ⇒ plusieurs règles, plusieurs d'entre elles sont « incertaines »

## ❖ Valeurs utilisées: MinSup 2 % -10 %, MinConf = 70 % - 90 %

# Approche 1: 1.Extraction des ensembles fréquents

- 
- ❖ D: une base de transactions
  - ❖ I: ensemble de tous les items avec  $|I|=n$

## Algorithme 1: Extraction des ensembles fréquents

Fréquents =  $\emptyset$

```
Pour chaque ensemble  $J \subseteq I$  Faire
    count( $J$ )=0
    Pour chaque transaction  $t \in D$  Faire
        Si  $J \subseteq t.items$  Alors
            count( $J$ )= count( $J$ )+1
        Si count( $J$ )  $\geq min\_support$  Alors
            Fréquents +=  $J$ 
    Fin
```

# Approche 1: 2.Extraction des règles

---

- ❖ **D**: une base de transactions
- ❖ **I**: ensemble de tous les items avec  $|I|=n$

## **Algorithme 2: Extraction des règles**

Règles =  $\emptyset$

**Pour chaque**  $J$  dans *Fréquents*

**Pour chaque** règle  $r: s \Rightarrow J \setminus s$  avec  $s \subset J, s \neq \emptyset$

**Si** confiance( $r$ )  $\geq \text{min\_confiance}$  **Alors**

Règles +=  $r$

**Fin**

# Approche 1: Estimation du coût

---

Algorithme 1: très coûteux.

- Pour chaque ensemble d'items  $J$ , il faut parcourir la base  $D$  pour compter le nombre de ses occurrences.
- Si  $n$  est le nombre d'items, il existe  $2^n$  ensembles  $J \rightarrow 2^n$  parcours de  $D$
- Accès successif à la base de données  $\rightarrow$  Nombre de calcul énorme

Algorithme 2: On peut supposer que l'ensemble « Fréquents » réside en mémoire et  $\text{count}(J)$  est une information déjà calculée par algorithme 1  $\rightarrow$  pas d'accès à  $D$

**$\rightarrow$  Coût global:  $2^n$  parcours de  $D$**

# Algorithme Apriori (Agrawal et Srikant, 1994)

---

**Principe** : Si un ensemble est non fréquent, alors tous ses sur-ensembles (super-set) ne sont pas fréquents, i.e.,

- Si  $\{ AB \}$  est fréquent alors  $\{ A \}$  et  $\{ B \}$  le sont
- Si  $\{ A \}$  n'est pas fréquent alors  $\{ AB \}$  ne peut pas l'être
- Itérativement, trouver les itemsets fréquents dont la cardinalité varie de 1 à k (k-itemset)
- Utiliser les itemsets fréquents pour générer les règles d'association

# Algorithme Apriori (Agrawal et Srikant, 1994)

- Étape de jointure:  $C_{k+1}$  est généré en joignant  $F_k$  avec lui même %  $F_k$ : itemset fréquent de taille k (k-itemset)
- Étape d'élagage: Chaque (k)-itemset qui n'est pas fréquent ne peut être un sous ensemble d'un (k+1)-itemset fréquent

$F_1 = \{\text{items fréquents}\};$

**for** ( $k = 1; F_k \neq \emptyset; k++$ ) **do**

$C_{k+1} = \text{candidats générés à partir de } F_k$  % jointure de  $F_k$

**for each** transaction  $t$  dans la base **do**

*incrémenter le COUNT des candidats de  $C_{k+1}$  qui sont dans t*

$F_{k+1} = \text{candidats dans } C_{k+1} \text{ dont COUNT} > \text{support\_min}$

**end for**

**end for**

**return**  $\bigcup_k F_k$

Sana Hamdi

17

# Génération de candidats: étape de jointure

---

- Self-join de  $F_k$ :

**insert into**  $C_{k+1}$

**select**  $p[1], p[2], \dots, p[k], q[k]$  **from**  $p, q$  (appartenant à  $F_k$ )

**where**  $p[1] = q[1], \dots, p[k - 1] = q[k - 1], p[k] < q[k]$

- Exemple:

- si  $F_3 = \{\{123\}, \{124\}, \{134\}, \{135\}, \{234\}\}$

→ la phase de jointure donne comme résultat  $C_4 = \{\{1234\}, \{1345\}\}$

# Génération de candidats: élagage de $C_k$

---

- La deuxième phase élagage de  $C_k$  : effacer les éléments qui ne vérifient pas la propriété des sous ensemble fréquents.

**Pour chaque *itemset c dans  $C_k$*  Faire**

**Pour chaque *(k-1)-sous-ensemble s de c* Faire**

**Si *(s n'est pas dans  $F_{k-1}$ )* Alors supprimer c de  $C_k$**

**Exemple:** si  $F_3 = \{\{123\}, \{124\}, \{134\}, \{135\}, \{234\}\}$

→ la phase joindre donne comme résultat  $C4 = \{\{1234\}, \{1345\}\}$

→ ensuite la phase d'élagage donne le résultat :  $C4 = \{\{1234\}$  car l'élément  $\{145\}$  n'est pas dans  $F_3$  et donc  $\{1345\}$  est effacé.

# Exemple1: Extraction des ensembles fréquents

---

- Avec une valeur de MinSup =2, appliquer l'algorithme "apriori" pour déterminer les ensembles fréquents à partir des transactions suivantes:

base D	
TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

# Exemple1: Extraction des ensembles fréquents

Avec min\_support=2

base D

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

$C_1$

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

$F_1$

itemset	sup.
{1}	2
{2}	3
{3}	3
{5}	3

$C_2$

itemset	sup
{1 2}	1
{1 3}	2
{2 3}	2
{2 5}	3
{3 5}	2

itemset
{1 2}
{1 3}
{1 5}
{2 3}
{2 5}
{3 5}

$F_2$

itemset	sup
{1 3}	2
{2 3}	2
{2 5}	3
{3 5}	2

itemset
{2 3 5}

itemset	sup
{2 3 5}	2

# Génération des règles d'association

---

Algorithme :

**pour chaque** itemset fréquent f

**pour chaque** sous ensemble s ⊂ f, avec  $s \neq \emptyset$

**si** confiance( $s \Rightarrow f \setminus s$ ) > min\_conf **alors**

afficher( $s \Rightarrow f \setminus s$ )

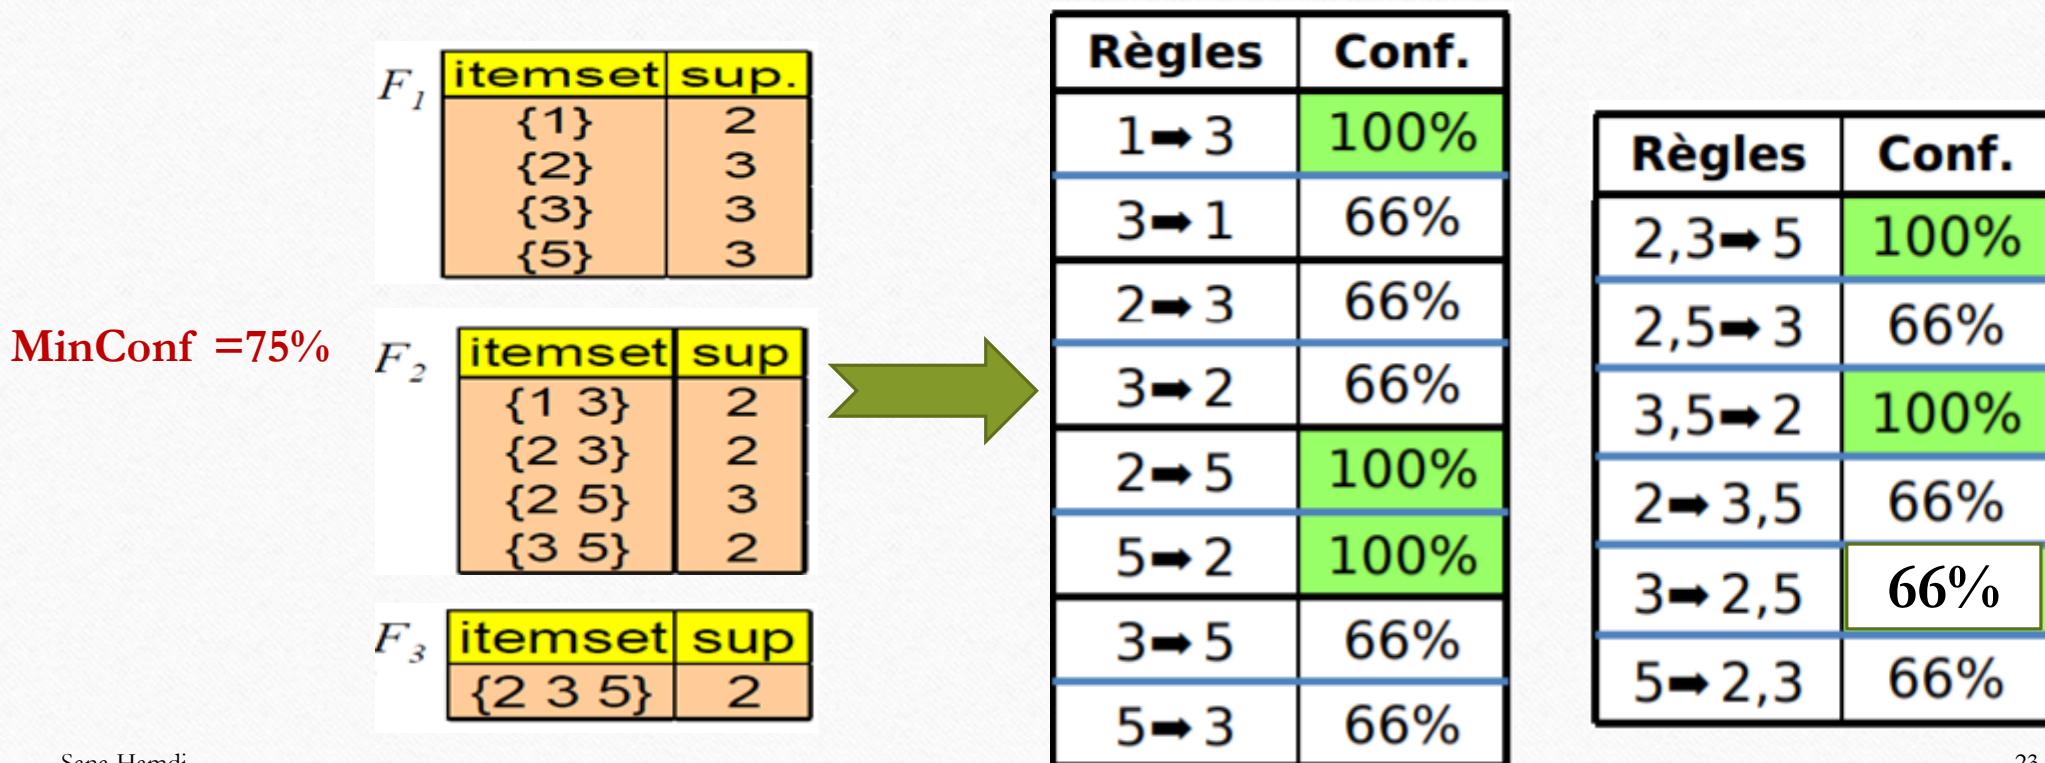
**fin pour**

**fin pour**

confiance ( $X \Rightarrow Y$ )  
=

support ( $X \Rightarrow Y$ ) / support (X)

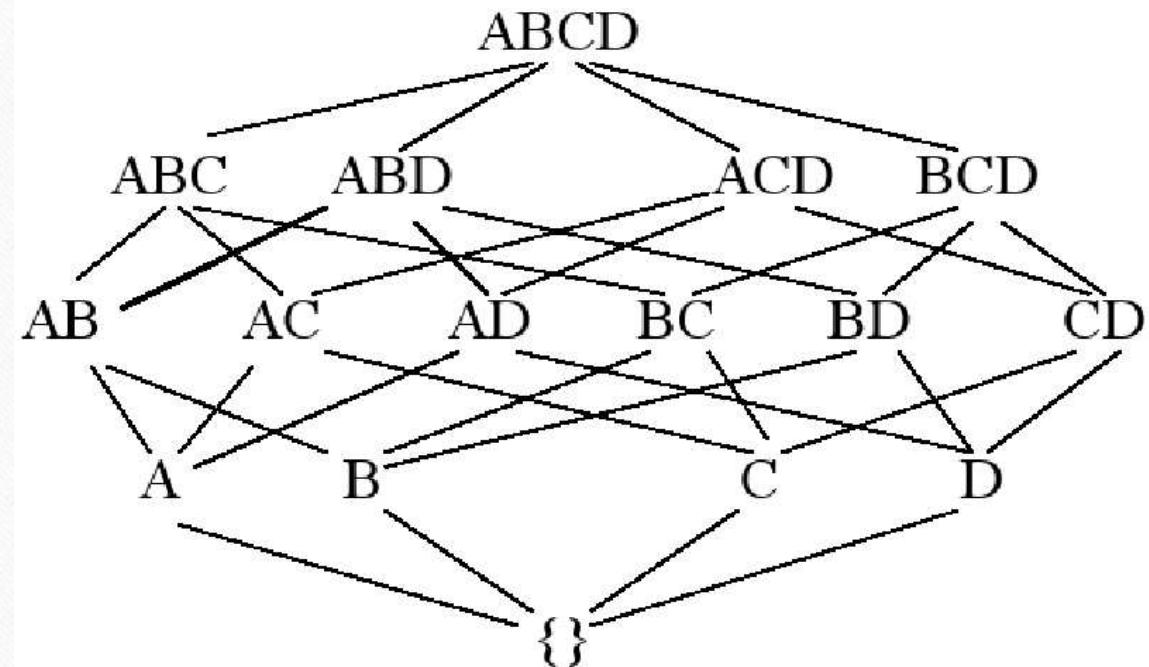
# Exemple 1: Génération des règles d'association



# Apriori: Exemple2

MinSup = 2

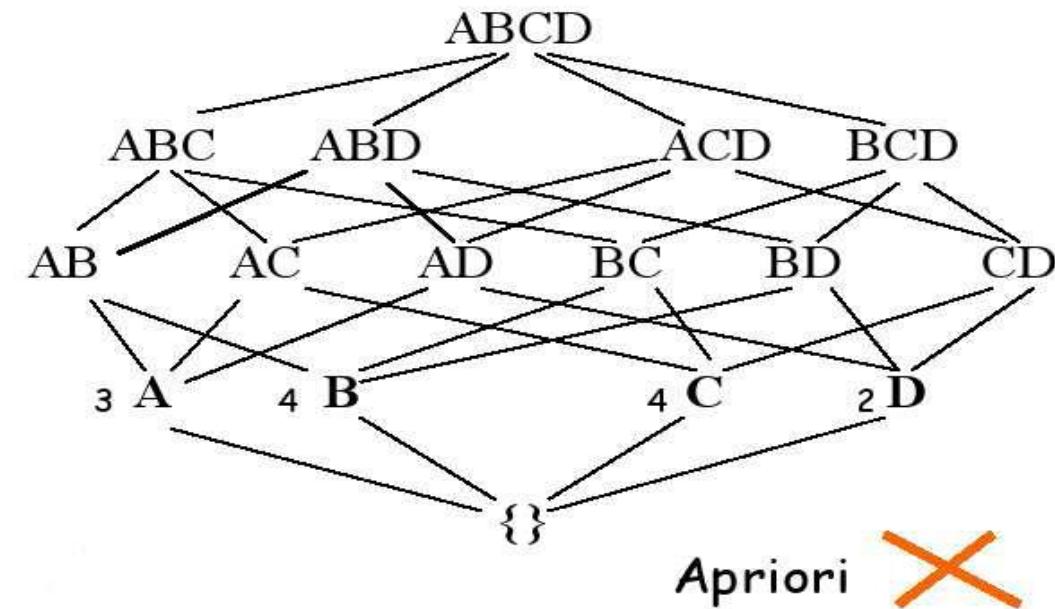
A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



# Apriori: Exemple2

MinSup = 2

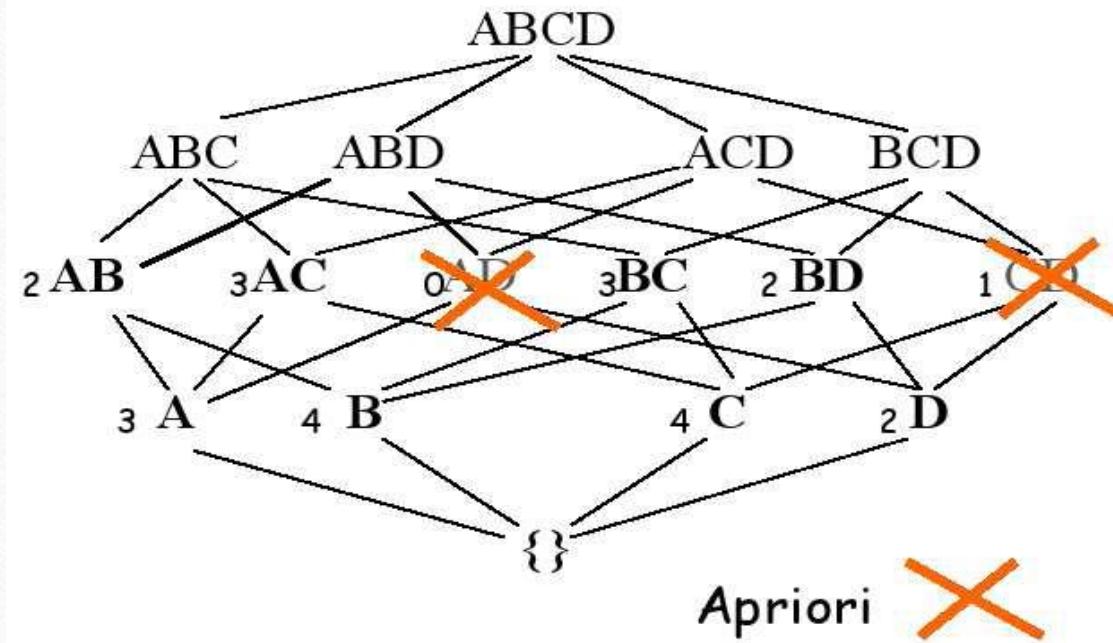
A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



# Apriori: Exemple2

MinSup = 2

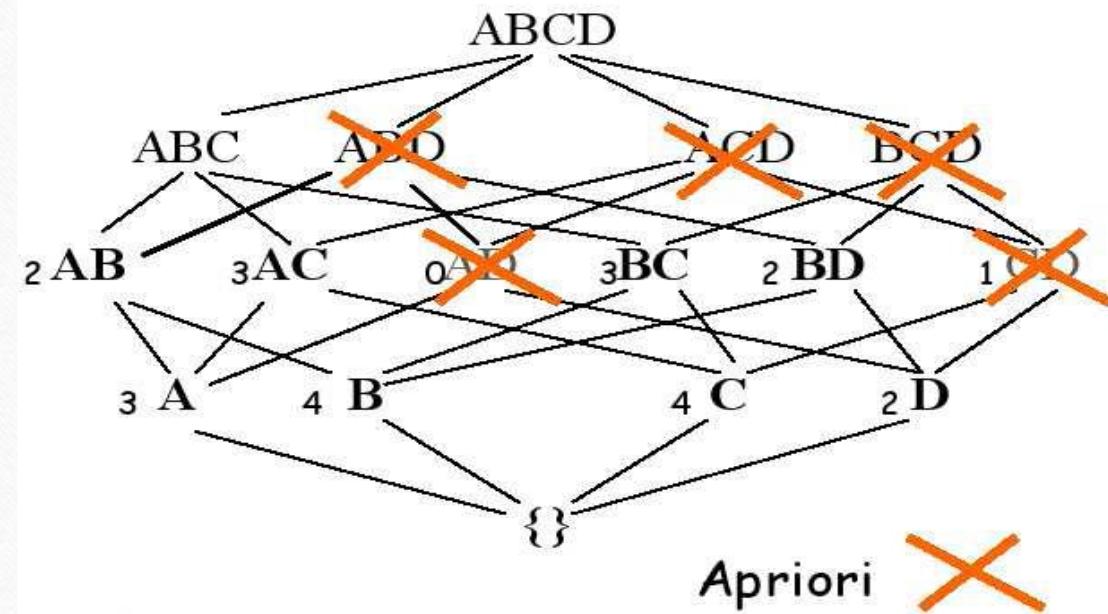
A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



# Apriori: Exemple2

MinSup = 2

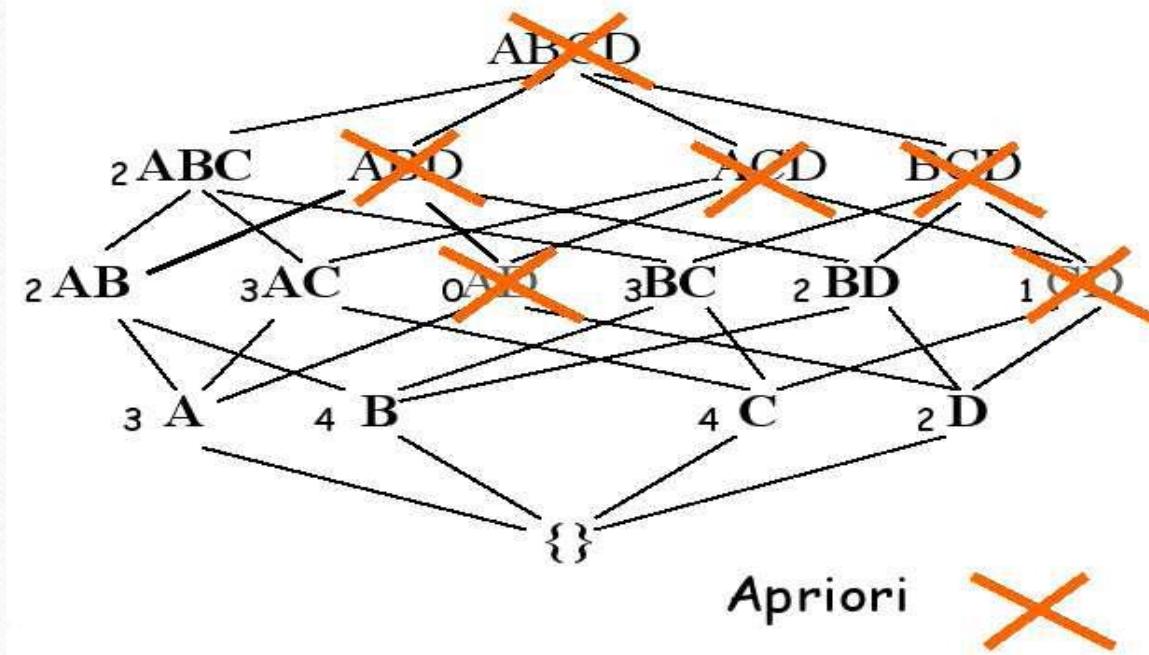
A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



# Apriori: Exemple2

MinSup = 2

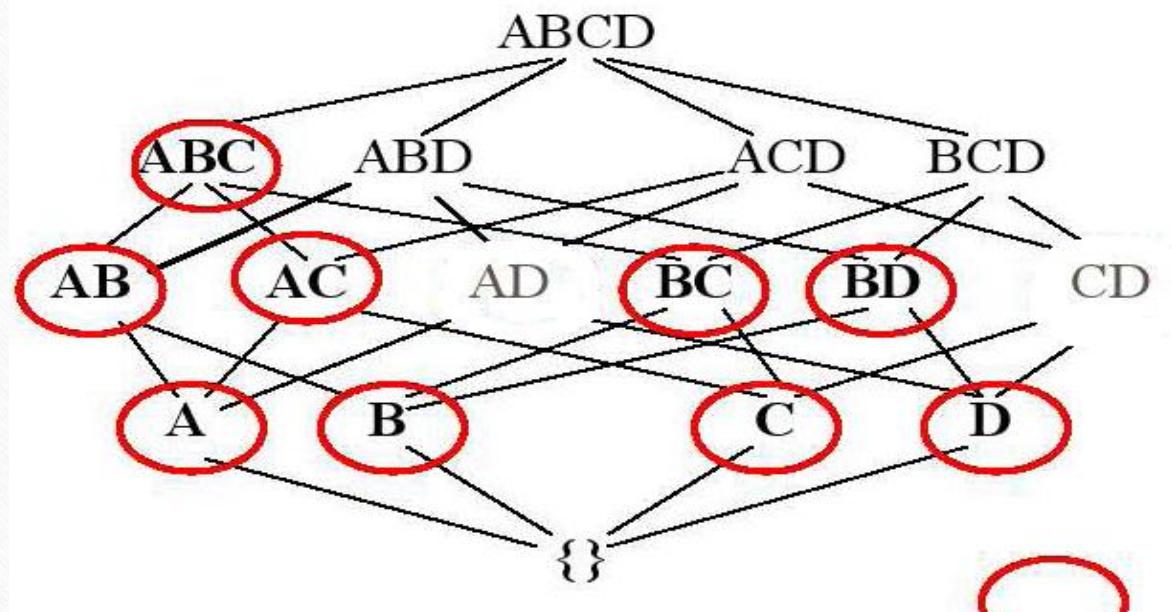
A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



# Apriori: Exemple2

MinSup = 2

A	B	C	D
1	0	1	0
1	1	1	0
0	1	1	1
0	1	0	1
1	1	1	0



Soit MinConf = 60%, donnez les règles d'associations

Itemsets valides

# Exercice: relations entre les mots

- On cherche des relations entre les mots d'un corpus sous forme de règles:  
**Si** les mots  $M_1, \dots, M_m$  apparaissent dans un texte **alors**  
les mots  $M_{m+1}, \dots, M_n$  apparaissent aussi dans le texte
- Dans le tableau suivant, nous avons 4 textes indexés par les mots clés A, B, C et D.

		textes				
		1	2	3	4	5
mots	A	X				
	B	X	X		X	X
	C			X	X	
	D	X				X

# Exercice: relations entre les mots

- Appliquer l'algorithme "apriori" pour déterminer les règles d'association valides avec un **SupMin = 40%** et **ConfMin = 50%**

		textes				
		1	2	3	4	5
mots	A	X				
	B	X	X		X	X
	C			X	X	
	D	X				X

# Exercice: relations entre les mots

---

- Avec **SupMin** = 40% et **ConfMin** = 50%: les deux règles valides sont :

$D \Rightarrow B$  et  $B \Rightarrow D$ .

- Avec **ConfMin** = 100%:

seule la règle:  $D \Rightarrow B$  est valide

# Apport d'information d'une règle

- Parfois une règle peut avoir d'excellents support et confiance, **MAIS**, sans être autant « **intéressante** »

## Exemple:

- X et Y positivement corrélés,
- X et Z négativement corrélés
- Les support et confiance de  $X \Rightarrow Z$  dominant
- Nous avons besoin d'une mesure de corrélation  $\text{Corr}_{(A, B)} = P(A \cap B) / P(A).P(B)$

X	1	1	1	1	0	0	0	0
Y	1	1	0	0	0	0	0	0
Z	0	1	1	1	1	1	1	1

# Apport d'information d'une règle

---

- Cette mesure est appelé: Intérêt (corrélation) ou aussi le Lift:

$$\text{Lift } (A \Rightarrow B) = \text{confiance}(A \Rightarrow B) / \text{Support } (B) = P(A \cap B) / P(A) \cdot P(B)$$

- ✓ prendre en compte  $P(A)$  et  $P(B)$
- ✓ Si  $\text{Lift} = 1$ , alors la règle ne sert absolument à rien: A et B sont indépendants:

$$P(A \cap B) = P(A) \cdot P(B), P(A), P(B) > 0$$

- ✓ Si  $\text{Lift } (A \Rightarrow B) < 1$ , alors A et B sont négativement corrélés
- ✓ Si  $\text{Lift } (A \Rightarrow B) > 1$ , alors A et B sont positivement corrélés (A est susceptible d'être acheté avec B)

# Apport d'information d'une règle

X	1	1	1	1	0	0	0	0
Y	1	1	0	0	0	0	0	0
Z	0	1	1	1	1	1	1	1



Itemset	Support	Intérêt
X,Y	25%	2
X,Z	37,50%	0,9
Y,Z	12,50%	0,57